

Correlation and Regression

การวิเคราะห์สหสัมพันธ์และการถดถอยเชิงเส้น

ผู้สอน: พศ.ดร. วรัญญู วงษ์เสรี

วัตถุประสงค์การเรียนรู้

เมื่อจบบทเรียนนี้ ผู้เรียนสามารถ

1. **เชื่อมโยง** Covariance, Correlation และความชันของเส้น ว่าเป็นปริมาณเดียวกันที่มองคนละมุม
2. **อธิบาย** ตัวประกอบของการถดถอย ทั้ง SSE และ R^2
3. **ประมาณค่า** เส้นถดถอยด้วย Ordinary Least Squares
4. **อธิบาย** การหาคำตอบด้วย Gradient Descent และบทบาทของ Learning rate
5. **ประเมิน** แบบจำลองด้วย Metrics และ Residual analysis

เนื้อหาของบทเรียน

หนึ่ง Covariance, Correlation และความชัน ที่มาจากปริมาณเดียวกัน

สอง ตัวประเมินของการถดถอย ทั้ง SSE และ R^2

สาม การหาเส้นที่ดีที่สุด ด้วย Normal Equation และ Gradient Descent

สี่ Multiple Linear Regression

ห้า การประเมินผลแบบจำลอง

มีการทดลองด้วยสนามทดลองสองครั้ง โดยลงมือทดลองก่อนเข้าเนื้อหาแต่ละส่วน

องค์ประกอบสามส่วนของ Regression

ทุกแบบจำลองในการเรียนรู้ของเครื่องประกอบด้วยสามส่วน เราใช้สามส่วนนี้เป็นแกนเล่าเรื่องทั้งหมด

- **Representation** รูปแบบของแบบจำลอง คือ เส้นตรง
- **Evaluation** ตัววัดความดี คือ SSE และ R^2
- **Optimization** วิธีหาคำตอบ คือ Normal Equation และ Gradient Descent

ก่อนเข้าสามส่วนนี้ ทำความรู้จัก Covariance และ Correlation ที่บอกว่าข้อมูลเกาะแนวเส้นมากเพียงใด

01

Covariance, Correlation and Slope

ปริมาณเดียวกันที่มองคนละมุม

ทดลอง — Quadrant และเครื่องหมายของผลคูณ

<https://waranyuwongseeree.github.io/correlation-fit-playground/>

แท็บ Correlation coefficient · เขียว=ผลคูณบวก แดง=ลบ

เป้าหมาย r	สีที่เด่นกว่า	$\text{cov}(x, y)$	r
0.9			
0.0			
-0.6			

คำถาม เมื่อสีเขียวด่นกว่า $\text{cov}(x, y)$ เป็นบวกหรือลบ

ทดลอง — การแกว่งของ r ตามจำนวนจุด

<https://waranyuwongseeree.github.io/correlation-fit-playground/>

ตั้ง r เป้าหมายศูนย์จุดเจ็ด สุ่มใหม่สามครั้งในแต่ละจำนวนจุด บันทึก r ที่อ่านได้

n	ครั้งที่ 1	ครั้งที่ 2	ครั้งที่ 3	ช่วง (มาก-น้อย)
10				
80				

คำถาม ช่วงการแกว่งของ r เท่ากับสิบ กว้างกว่าของแปดสิบประมาณกี่เท่า

ทดลอง — ข้อมูลโค้ง

<https://waranyuwongseeree.github.io/correlation-fit-playground/>

สลับรูปแบบข้อมูล แล้วอ่าน r และ R^2

รูปแบบข้อมูล	r	R^2
linear		
curved		

คำถาม ข้อมูล curved มีความสัมพันธ์ชัดเจน แต่ค่า r ที่อ่านได้เป็นเท่าใด อธิบายว่าทำไมจึงต่ำ

ทดลอง — จุดผิดปกติ (outlier)

<https://waranyuwongseeree.github.io/correlation-fit-playground/>

ตั้ง r เป้าหมายศูนย์จุดแปด อ่าน r และ w_1 ก่อนและหลังเปิดสวิตช์ outlier

สถานะ	r	w_1
ไม่มี outlier		
มี outlier		

คำถาม outlier เพียงจุดเดียวทำให้ w_1 เปลี่ยนไปที่หน่วย

ทดลอง — SSE และ R^2

<https://waranyuwongseeree.github.io/correlation-fit-playground/>

เก็บ Goodness of fit อ่าน SSE, SST, R^2 ที่ระดับสัญญาณรบกวนต่าง ๆ

สัญญาณรบกวน	SSE	SST	R^2	r^2
ต่ำ				
สูง				


คำถาม ค่า R^2 เท่ากับ r^2 ทุกแถวหรือไม่ และเมื่อ SSE เพิ่มขึ้น R^2 เปลี่ยนอย่างไร

เริ่มจากความสัมพันธ์ของสองตัวแปร

การถดถอย คือ การลากเส้นเพื่อทำนาย y จาก x แต่ก่อนลากเส้น ต้องตอบก่อนว่าสองตัวแปรสัมพันธ์กันมากเพียงใด


คำถาม คือ เมื่อ x มากกว่าค่าเฉลี่ย แล้ว y มีแนวโน้ม
มากกว่าค่าเฉลี่ยตามไปด้วยหรือไม่

เครื่องมือแรกที่ต้องตอบ คือ Covariance



Covariance

$$\text{cov}(x, y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$



หัวใจอยู่ที่พจน์ร่วม $(x_i - \bar{x})(y_i - \bar{y})$


- ไปทางเดียวกัน ผลคูณ**เป็นบวก**
- สวนทางกัน ผลคูณ**เป็นลบ**
- ผลรวมทุกจุด คือ ทิศของการไปด้วยกัน

ตัวอย่างการคำนวณ Covariance

x_i	y_i	$x_i - \bar{x}$	$y_i - \bar{y}$	ผลคูณ
1	1	-2	-2	4
2	3	-1	0	0
3	2	0	-1	0
4	5	1	2	2
5	4	2	1	2

ค่าเฉลี่ยเท่ากับสามทั้งคู่ ผลรวมพจน์ร่วมเท่ากับแปด

$$\text{cov}(x, y) = \frac{8}{5} = 1.6$$



จาก Covariance สู่ Correlation


Covariance เป็นค่าดิบที่ยังมีหน่วย Correlation คือ Covariance ที่ปรับให้เป็นมาตรฐานด้วยส่วนเบี่ยงเบนของทั้งสองแกน

$x_i - \bar{x}$	$(x_i - \bar{x})^2$	$(y_i - \bar{y})^2$
-2	4	4
-1	1	0
0	0	1
1	1	4
2	4	1
รวม	10	10

$$r = \frac{\text{cov}(x, y)}{s_x s_y} = \frac{8}{\sqrt{10} \sqrt{10}} = 0.8$$


ผลรวมกำลังสองของส่วนเบี่ยงเบนของแต่ละแกนเท่ากับสิบ
จึงได้ Correlation เท่ากับศูนย์จุดแปด

Correlation บอกความแข็งแรงของแนวเส้น



ค่าเข้าใกล้บวกหนึ่งหรือลบหนึ่ง คือ เกาะแนวเส้นแข็งแรง ค่าเข้าใกล้ศูนย์ คือ แทบไม่มีแนวเส้น


Correlation ของตัวอย่างจะแกว่ง



ค่าของประชากรเป็นค่าคงที่ แต่ค่าจากตัวอย่างจำนวน
จำกัดจะแกว่งรอบค่าจริง ยิ่งตัวอย่างน้อย ยิ่งแกว่งมาก

Correlation สูงไม่ได้แปลว่าเป็นเหตุเป็นผลกัน

กับดัก ค่าสรุปเหมือนกันแต่ข้อมูลต่างกัน



ทั้งสี่ชุดมีค่าสรุปเหมือนกัน แต่รูปร่างต่างกันสิ้นเชิง จึงต้องมองภาพข้อมูลเสมอ

ความชันของเส้นถดถอย

แบบจำลองเชิงเส้นเขียนได้เป็น

$$\hat{y} = w_0 + w_1x$$

ความชันที่ทำให้เส้นเข้ากับข้อมูลดีที่สุด สร้างจากพจน์ร่วมตัวเดิม จากข้อมูลชุดเดิม

$$w_1 = \frac{\text{cov}(x, y)}{\text{var}(x)} = \frac{8}{10} = 0.8 \quad w_0 = \bar{y} - w_1\bar{x} = 3 - 0.8 \cdot 3 = 0.6$$

พจน์ร่วมเดียวกัน

$$\text{cov}(x, y) = \frac{1}{n} \sum_i (x_i - \bar{x})(y_i - \bar{y})$$

$$r = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2} \sqrt{\sum_i (y_i - \bar{y})^2}}$$

$$w_1 = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2}$$


พจน์ที่เน้นสีน้ำเงิน คือ พจน์ร่วมตัวเดียวกัน ปรากฏในทั้งสามสมการ

ปริมาณเดียว สามมุมมอง

มุมมอง	สูตร	ตัวที่ใช้ปรับมาตรฐาน
Covariance	$\frac{1}{n} \sum (x_i - \bar{x})(y_i - \bar{y})$	จำนวนข้อมูล
Correlation r	$\frac{\text{cov}(x, y)}{s_x s_y}$	ส่วนเบี่ยงเบนของสองแกน
ความชัน w_1	$\frac{\text{cov}(x, y)}{\text{var}(x)}$	ความแปรปรวนของ x

ทั้งสามสร้างจากพจน์ร่วมตัวเดียวกัน ต่างกันเพียงตัวที่นำไปหาร

ไล่ระดับแบบจำลองเชิงเส้น



แบบจำลองที่ซับซ้อนขึ้นมีพารามิเตอร์มากขึ้น เริ่มจากเส้นแบน ไปเส้นผ่านจุดกำเนิด แล้วจึงเป็นเส้นเต็มรูป

02


Evaluation ของการถดถอย

วัดความดีของเส้นด้วย SSE และ R^2


แบบจำลองเชิงเส้นและ Residual

ได้แบบจำลองเชิงเส้น $\hat{y} = w_0 + w_1x$ แล้ว ต้องตัดสินใจว่าเส้นดีเพียงใด วัดจาก Residual คือ ระยะในแนวตั้งจากจุดจริงถึงเส้น

$$e_i = y_i - \hat{y}_i$$




SSE — ผลรวมกำลังสองของส่วนเหลือ



$$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

แต่ละส่วนเหลือ คือ ด้านของสี่เหลี่ยม พื้นที่ คือ กำลังสอง
SSE คือ ผลรวมพื้นที่ ยิ่งน้อยเส้นยิ่งดี


เทียบกับเส้นฐาน — SST



$$SST = \sum_{i=1}^n (y_i - \bar{y})^2$$

เส้นฐาน คือ การยกด้วยค่าเฉลี่ยทุกครั้ง SST คือ ความแปรปรวนทั้งหมดที่อยากให้เส้นอธิบาย

การแยกความแปรปรวน



ต่อหนึ่งจุด ความยาวบวกกันได้พอดี

$$(y - \bar{y}) = (\hat{y} - \bar{y}) + (y - \hat{y})$$

ยกกำลังสองแล้วรวมทุกจุด พจน์ไขว้เป็นศูนย์ จึงได้

$$SST = SSR + SSE$$

R^2 — สัมประสิทธิ์การตัดสินใจ

$$R^2 = 1 - \frac{SSE}{SST} = \frac{SSR}{SST}$$

- ค่าเข้าใกล้หนึ่ง คือ เส้นอธิบายข้อมูลได้ดี
- ค่าเข้าใกล้ศูนย์ คือ เส้นแทบไม่ดีกว่าการทายด้วยค่าเฉลี่ย

R^2 คือ SSE ในรูปสัดส่วน เทียบข้ามปัญหาได้

กรณีพิเศษ ของตัวแปรเดียว

เฉพาะ Simple Linear Regression ค่า R^2 เท่ากับกำลังสองของ Correlation

$$R^2 = r^2$$

เป็นเพราะความชันสร้างจาก Correlation สดส่วนที่เส้นอธิบายได้จึงออกมาเป็นกำลังสองพอดี

เมื่อมีหลายตัวแปร ความสัมพันธ์ตรงนี้จะไม่เป็นเช่นนี้


ยืนยันด้วยข้อมูลชุดเดิม

จากข้อมูลห้าจุดชุดเดิม ได้ค่าครบแล้ว Covariance เท่ากับ 1.6 Correlation เท่ากับ 0.8 และเส้น $\hat{y} = 0.6 + 0.8x$

$$R^2 = 1 - \frac{3.6}{10} = 0.64$$

$$r^2 = 0.8^2 = 0.64$$

ตรงกันพอดี



03

Optimization

จากข้อมูล สู่ Cost function สู่ Gradient Descent

หาเส้นที่ดีที่สุดได้อย่างไร

เราอยากเลือก w_0 และ w_1 ที่ทำให้เส้นเข้ากับข้อมูลมากที่สุด

แนวคิด คือ วัดความผิดพลาดของแต่ละทางเลือกด้วยตัวเลขเดียว แล้วเลือกทางเลือกที่ความผิดพลาดน้อยที่สุด

$$E(w_0, w_1) = \frac{1}{2n} \sum_{i=1}^n (h(x^{(i)}) - y^{(i)})^2$$

ตัวเลขนี้ คือ Cost function จากข้อมูลนำไปสู่ Cost function และนำไปสู่การหาจุดต่ำสุด

ตัวอย่างง่าย หา Cost function

ใช้ข้อมูลสองจุด คือ $(0, 0)$ และ $(2, 2)$ และแบบจำลองผ่านจุดกำเนิด $h(x) = w_1x$


$$E(w_1) = \frac{1}{2 \cdot 2} \left[(w_1 \cdot 0 - 0)^2 + (w_1 \cdot 2 - 2)^2 \right] = \frac{1}{4} (2w_1 - 2)^2 = (w_1 - 1)^2$$

Cost function เป็นฟังก์ชันของ w_1 เพียงตัวเดียว ต่อไปลองแทนค่าทีละค่า

ลอง w_1 เท่ากับศูนย์

แบบจำลอง คือ เส้นแบน เส้นไม่ผ่านจุด $(2, 2)$ ค่าความผิดพลาดสูง


$$E(0) = (0 - 1)^2 = 1$$



ลอง w_1 เท่ากับหนึ่ง

แบบจำลองผ่านทั้งสองจุดพอดี ค่าความผิดพลาดเป็นศูนย์


$$E(1) = (1 - 1)^2 = 0$$



ลอง w_1 เท่ากับสอง แล้วได้กราฟรูปสาม

ความชันมากเกินไป เส้นเลยจุด $(2, 2)$ ค่าความผิดพลาดกลับมาสูง

$$E(2) = (2 - 1)^2 = 1$$



จุดต่ำสุดของกราฟรูปสามที่ w_1 เท่ากับหนึ่ง คือ คำตอบ

Normal Equation

ที่จุดต่ำสุด ความชันของ Cost function เป็นศูนย์ ให้อนุพันธ์เป็นศูนย์แล้วแก้ ได้สูตรปิด

$$\frac{\partial \text{SSE}}{\partial w_0} = 0 \quad \frac{\partial \text{SSE}}{\partial w_1} = 0$$
$$\hat{w}_1 = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2} \quad \hat{w}_0 = \bar{y} - \hat{w}_1 \bar{x}$$

พิเศษ คือ พจน์ร่วมตัวเดิม การแก้สมการได้คำตอบในขั้นตอนเดียว

03.1

Gradient Descent

แนวคิดทั่วไปของการเดินลงเขา

ทดลอง — Pure 1D และ Learning rate

<https://waranyuwongseeree.github.io/gradient-descent-playground/>

เก็บ Pure 1D ฟังก์ชัน Quadratic นับจำนวนรอบจนลู่เข้าในแต่ละ Learning rate

Learning rate	จำนวนรอบ	ลู่เข้า/ลู่ออก
0.05		
0.30		
1.10		

คำถาม ค่าใดลู่เข้าเร็วที่สุด และค่าใดเริ่มลู่ออก

ทดลอง — Pure 2D และ Gradient เวกเตอร์

<https://waranyuwongseeree.github.io/gradient-descent-playground/>

แก้ Pure 2D ใช้ Learning rate เท่ากัน นับจำนวนรอบของแต่ละฟังก์ชัน

ฟังก์ชัน	จำนวนรอบจนลู่เข้า
Round bowl	
Ill-conditioned	

คำถาม ฟังก์ชันใดใช้รอบมากกว่า และที่ Saddle ความชันเป็นศูนย์แต่เป็นจุดต่ำสุดหรือไม่

ทดลอง — Worked example สองจุด

<https://waranyuwongseeree.github.io/gradient-descent-playground/>

เห็น Worked example (2 points) ตั้งต้น w เท่ากับสอง กด Step แล้วบันทึก w ทีละก้าว

ก้าวที่	0	1	2	3
w	2			

คำถาม ค่า w เข้าใกล้ค่าใด ตรงกับการคำนวณด้วยมือหรือไม่

ทดลอง — Regression through the origin

<https://waranyuwongseeree.github.io/gradient-descent-playground/>

แก้ Regression through the origin อ่านค่า E ต่ำสุดหลังใส่ค่า ที่ระดับสัญญาณรบกวนต่าง ๆ

สัญญาณรบกวน	E ต่ำสุด
0.1	
0.4	

คำถาม เมื่อสัญญาณรบกวนเพิ่มเป็นสี่เท่า ค่า E ต่ำสุดเปลี่ยนไปอย่างไร

ทดลอง — Simple linear regression สองมิติ

<https://waranyuwongseeree.github.io/gradient-descent-playground/>

แท็บ Simple linear regression นับจำนวนรอบจนลู่เข้าในแต่ละ Learning rate


Learning rate	จำนวนรอบจนลู่เข้า
0.10	
0.30	

คำถาม Learning rate ที่สูงขึ้นใช้จำนวนรอบมากขึ้นหรือน้อยลง

ความชันของ Cost function

ก่อนเดินลงเขา ต้องรู้ทิศ ที่จุดใด ความชันของ Cost function บอกทิศ จากตัวอย่างก่อนหน้านี้

$$E(w_1) = (w_1 - 1)^2 \quad \frac{dE}{dw_1} = 2(w_1 - 1)$$



- ความชันเป็นบวก ก็น่าจะอยู่ทางซ้าย
- จึงเดินใน**ทิศตรงข้ามกับความชัน**
- ที่จุดต่ำสุด ความชันเป็นศูนย์ จึงหยุด

กฎการปรับค่า

กำหนดค่าเริ่มต้น แล้วปรับพารามิเตอร์ในทิศทางข้ามกับความชัน ทีละก้าว


$$w_1 := w_1 - \alpha \frac{dE}{dw_1}$$

โดย α คือ Learning rate ควบคุมขนาดของก้าว ทำซ้ำจนความชันเข้าใกล้ศูนย์


ตัวอย่างเชิงตัวเลข

กำหนด w_1 เริ่มต้นเท่ากับสอง และ α เท่ากับศูนย์จุดห้า

$$\left. \frac{dE}{dw_1} \right|_{w_1=2} = 2(2 - 1) = 2 \quad w_1 := 2 - 0.5 \times 2 = 1$$




Learning rate น้อยเกินไป



แต่ละก้าวสั้นมาก ต้องใช้จำนวนรอบมากกว่าจะลู่เข้าสู่จุดต่ำสุด

Learning rate มากเกินไป




แต่ละก้าวข้ามจุดต่ำสุด ค่าผิดพลาดกระโดดสูงขึ้น และลู่ออกในที่สุด

Gradient Descent สองมิติ

เมื่อมีพารามิเตอร์สองตัว ความชันกลายเป็น Gradient ซึ่ง คือ เวกเตอร์ของอนุพันธ์ย่อย ตัวอย่างฟังก์ชัน

$$f(w_0, w_1) = w_0^2 + w_1^2$$

$$\nabla f = \left(\frac{\partial f}{\partial w_0}, \frac{\partial f}{\partial w_1} \right) = (2w_0, 2w_1)$$



ที่จุด $(3, 2)$ Gradient เท่ากับเวกเตอร์ $(6, 4)$ ปรับค่าในทิศตรงข้าม


$$(w_0, w_1) := (3, 2) - \alpha(6, 4)$$

เมื่อ α เท่ากับศูนย์จุดหนึ่ง ได้ $(2.4, 1.6)$

เชื่อม Gradient Descent เข้ากับการถดถอย

นำกฎเดียวกันมาใช้กับ Cost function ของการถดถอย Gradient คือ เวกเตอร์ของอนุพันธ์ย่อยสองตัว

$$\frac{\partial E}{\partial w_0} = \frac{1}{n} \sum_i (w_0 + w_1 x^{(i)} - y^{(i)}) \quad \frac{\partial E}{\partial w_1} = \frac{1}{n} \sum_i (w_0 + w_1 x^{(i)} - y^{(i)}) x^{(i)}$$



04

Multiple Linear Regression

หลายตัวแปร และรูปเมทริกซ์

จากหนึ่งตัวแปรสู่หลายตัวแปร

$$h(\mathbf{x}) = w_0 + w_1x_1 + w_2x_2 + \cdots + w_dx_d$$

รูปเมทริกซ์ และสูตรปิด

$$\mathbf{y} = \mathbf{X}\mathbf{w} + \boldsymbol{\varepsilon} \quad \hat{\mathbf{w}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$$

Evaluation ยังเป็น MSE และ Optimization ยังใช้ Normal Equation หรือ Gradient Descent เหมือนเดิม

Gradient Descent เทียบ Normal Equation

Gradient Descent

- ต้องเลือก Learning rate
- ต้องทำซ้ำหลายรอบ
- ทำงานได้ดีเมื่อตัวแปรมาก

Normal Equation

- ไม่ต้องเลือก Learning rate
- ไม่ต้องทำซ้ำ
- ช้าเมื่อตัวแปรมาก เพราะต้องหาเมทริกซ์ผกผัน

Multicollinearity

เมื่อตัวแปรอิสระสัมพันธ์กันสูง ค่าสัมประสิทธิ์ไม่เสถียร และตีความได้ยาก ตรวจสอบด้วย Variance Inflation Factor

$$\text{VIF}_j = \frac{1}{1 - R_j^2}$$

ค่าต่ำกว่าห้า ยอมรับได้ ค่าตั้งแต่สิบขึ้นไป ถือว่ามีปัญหารุนแรง

05

การประเมินผลแบบจำลอง

Metrics และ Residual Analysis


Regression Metrics

Metric	สูตร	ความหมาย	ทิศที่ดี
MAE	$\frac{1}{n} \sum y_i - \hat{y}_i $	ความผิดพลาดเฉลี่ย	ต่ำ
RMSE	$\sqrt{\frac{1}{n} \sum (y_i - \hat{y}_i)^2}$	ลงโทษค่าผิดพลาดมากกว่า	ต่ำ
R^2	$1 - \frac{SSE}{SST}$	สัดส่วนที่อธิบายได้	สูง

RMSE มีหน่วยเดียวกับ y ที่ความง่าย

Residual Analysis

ตรวจ Residual เทียบกับค่าทำนาย ที่ดีต้องกระจายสุ่มรอบศูนย์ ไม่มีรูปแบบ



เห็นรูปโค้ง คือ ความสัมพันธ์ไม่เป็นเชิงเส้น การกระจายขยายตัว คือ ความแปรปรวนไม่คงที่

Assumptions (LINE)

Assumption	ความหมาย	วิธีตรวจสอบ
Linearity	ความสัมพันธ์เป็นเส้นตรง	Residual vs Fitted
Independence	ข้อมูลอิสระต่อกัน	Durbin-Watson
Normality	Residual แจกแจงปกติ	Q-Q plot
Equal variance	ความแปรปรวนคงที่ (Homoscedasticity)	Scale-Location plot

06

สรุป

บททวนเส้นเรื่องของบทเรียน

สรุปบทเรียน

- Covariance, Correlation และความชัน สร้างจากพจน์ร่วมตัวเดียวกัน
- ตัวประเมินของการถดถอย คือ SSE และ R^2 โดย SST เท่ากับ SSR บวก SSE
- ความสัมพันธ์ R^2 เท่ากับ r^2 เป็นเพียงกรณีพิเศษของตัวแปรเดียว
- หาเส้นด้วย Normal Equation หรือ Gradient Descent ซึ่งมี Learning rate เป็นตัวควบคุมสำคัญ

คำถาม

Questions and Discussion

ผศ.ดร. วรรณญ วงษ์เสรี