

Generalization

การวางนัยทั่วไป

Asst. Prof. Dr. Waranyu Wongseree

Chitralada Technology Institute (CDTI)

บทวนหัวข้อที่แล้ว — การถดถอยและสหสัมพันธ์

หัวข้อที่แล้ว เราเรียนการ**ฟิตเส้น**ให้เข้ากับข้อมูล — หาค่าสัมประสิทธิ์ w ที่ทำให้ผลรวมกำลังสองของค่าคลาดเคลื่อน (RMSE) ต่ำที่สุด

แยก **สหสัมพันธ์** (ความสัมพันธ์เชิงเส้น) ออกจาก **การถดถอย** (ทำนายค่า) และใช้ **gradient descent** ไล่ลงหาจุดต่ำสุดของฟังก์ชันต้นทุน

ทั้งหมดนั้นวัดบน**ข้อมูลที่เห็นแล้ว** — แต่กับข้อมูลใหม่ที่ไม่เคยเห็นล่ะ?

เป้าหมายจริงของการเรียนรู้

เราหาเส้นที่ทำให้ค่าคลาดเคลื่อน**ในตัวอย่าง**น้อยที่สุด


แต่เป้าหมายจริง คือ ทาย **ข้อมูลใหม่** ที่ไม่เคยเห็นให้แม่น

คำถามของบทนี้: ค่าคลาดเคลื่อนในตัวอย่างต่ำ แปลว่าดีจริงหรือไม่?

โจทย์


ฟังก์ชันเป้าหมายที่ต้องการเรียนรู้ คือ $f(x) = \sin(\pi x)$

เส้นสีเขียวคือความจริงที่ยังไม่ปรากฏในทางปฏิบัติ




ข้อมูลที่สุมมา

ในทางปฏิบัติ สุ่มตัวอย่างจาก f ได้เพียงไม่กี่จุด สมมติ 2 จุด เรียกว่าชุดข้อมูล D




สิ่งที่นักวิเคราะห์มีจริง

ผู้วิเคราะห์ไม่เห็นเส้นเป้าหมาย เห็นเพียงจุดข้อมูล ฟังก์ชัน
จริง f ถูกซ่อนไว้



สร้างแบบจำลอง

ฟิตเส้นตรง $g_D(x)$ (เส้นดำ) ให้ผ่านจุดข้อมูล




ค่าคลาดเคลื่อนในตัวอย่าง

วัดความคลาดเคลื่อนของแบบจำลองบนจุดที่ใช้ฝึก

$$E_{\text{in}}(g_D) = \frac{1}{n} \sum_{i=1}^n (g_D(x_i) - y_i)^2$$

เส้นตรงผ่าน 2 จุดพอดี ดังนั้น $E_{\text{in}} = 0$ อย่างไรก็ตามค่านี้ยังไม่บ่งชี้สมรรถนะกับข้อมูลใหม่




ค่าคลาดเคลื่อนนอกตัวอย่าง

ค่าที่แท้จริง คือ แบบจำลองห่างจาก f เพียงใดตลอดช่วง x

$$E_{\text{out}}(g_D) = \mathbb{E}_x [(g_D(x) - f(x))^2]$$

เป็นค่าในอุดมคติที่ใช้เพื่อการพิสูจน์




ข้อควรรู้

E_{out} เป็นค่าใน **อุดมคติ**


ในทางปฏิบัติคำนวณ**ไม่ได้โดยตรง** เพราะไม่ทราบ
 f

ใช้เพื่อการพิสูจน์และทำความเข้าใจเท่านั้น (แถบแดงในรูปคือ
ช่องว่างที่วัดไม่ได้จริง)




ชุดข้อมูลเดียวไม่ยุติธรรม

ชุดข้อมูลที่ต่างกันให้เส้นที่ต่างกัน และไม่ทราบว่าจะได้ชุดใด



จึงเฉลี่ยเหนือทุกชุดข้อมูล

จึงพิจารณาค่าเฉลี่ยของ E_{out} เหนือชุดข้อมูล D ทั้งหมดที่เป็นไปได้ (สี: $\mathbf{x}$ ตัวแปรอินพุต, D ชุดข้อมูล)



$$\mathbb{E}_D [E_{\text{out}}(g_D)] = \mathbb{E}_D \mathbb{E}_{\mathbf{x}} [(g_D(\mathbf{x}) - f(\mathbf{x}))^2]$$

สลับลำดับการเฉลี่ย

เนื่องจาก $\mathbb{E}_{\mathbf{x}}$ และ $\mathbb{E}_D$ สลับลำดับกันได้

$$\begin{aligned}\mathbb{E}_D [E_{\text{out}}(g_D)] &= \mathbb{E}_D \mathbb{E}_{\mathbf{x}} [(g_D(\mathbf{x}) - f(\mathbf{x}))^2] \\ &= \mathbb{E}_{\mathbf{x}} \mathbb{E}_D [(g_D(\mathbf{x}) - f(\mathbf{x}))^2]\end{aligned}$$

จากนี้พิจารณาพจน์ภายใน $\mathbb{E}_D[\cdot]$ ซึ่งทุกฟังก์ชันยังแปรผันตาม $\mathbf{x}$

กระจายพจน์ยกกำลังสอง

$$\begin{aligned}\mathbb{E}_D[(g_D(\mathbf{x}) - f(\mathbf{x}))^2] &= \mathbb{E}_D[g_D(\mathbf{x})^2] - 2\mathbb{E}_D[g_D(\mathbf{x})f(\mathbf{x})] + \mathbb{E}_D[f(\mathbf{x})^2] \\ &= \mathbb{E}_D[g_D(\mathbf{x})^2] - 2\mathbb{E}_D[g_D(\mathbf{x})]f(\mathbf{x}) + f(\mathbf{x})^2\end{aligned}$$

เนื่องจาก $f(\mathbf{x})$ ไม่แปรผันตาม D ดังนั้น $\mathbb{E}_D[f(\mathbf{x})] = f(\mathbf{x})$

ความหมาย: แยกความคลาดเคลื่อนกำลังสองออกเป็นสามพจน์ เพื่อเตรียมจัดกลุ่มเป็น variance และ bias ในหน้าถัดไป

แบบจำลองเฉลี่ย


พจน์ $\mathbb{E}_D[g_D(\mathbf{x})]$ คือแบบจำลองเฉลี่ยเหนือทุกชุดข้อมูล นิยาม

$$\bar{g}(\mathbf{x}) = \mathbb{E}_D[g_D(\mathbf{x})]$$

แทนกลับในผลจากหน้าก่อน จะได้

$$\mathbb{E}_D[(g_D(\mathbf{x}) - f(\mathbf{x}))^2] = \mathbb{E}_D[g_D(\mathbf{x})^2] - 2\bar{g}(\mathbf{x})f(\mathbf{x}) + f(\mathbf{x})^2$$

เส้นแดงคือแบบจำลองเฉลี่ย $\bar{g}$ จากเส้นสุ่มจำนวนมาก



จัดกลุ่มใหม่ด้วย $\bar{g}^2$

บวกและลบ $\bar{g}(\mathbf{x})^2$ แล้วจัดกลุ่มใหม่

$$\begin{aligned}\mathbb{E}_D[g_D(\mathbf{x})^2] - 2\bar{g}(\mathbf{x})f(\mathbf{x}) + f(\mathbf{x})^2 &= (\mathbb{E}_D[g_D(\mathbf{x})^2] - \bar{g}(\mathbf{x})^2) + (\bar{g}(\mathbf{x})^2 - 2\bar{g}(\mathbf{x})f(\mathbf{x}) + f(\mathbf{x})^2) \\ &= \underbrace{\mathbb{E}_D[g_D(\mathbf{x})^2] - \bar{g}(\mathbf{x})^2}_{\text{var}(\mathbf{x})} + \underbrace{(\bar{g}(\mathbf{x}) - f(\mathbf{x}))^2}_{\text{bias}(\mathbf{x})^2}\end{aligned}$$

ก้อนแรกคือความแปรปรวน ก้อนที่สองเป็นกำลังสองสมบูรณ์ $(\bar{g} - f)^2$ คือความเอนเอียงยกกำลังสอง



Variance — ความกว้างของแบบจำลอง

ณ แต่ละจุด $\mathbf{x}$

$$\begin{aligned}\text{var}(\mathbf{x}) &= \mathbb{E}_D [(g_D(\mathbf{x}) - \bar{g}(\mathbf{x}))^2] \\ &= \mathbb{E}_D [g_D(\mathbf{x})^2] - 2 \mathbb{E}_D [g_D(\mathbf{x})] \bar{g}(\mathbf{x}) + \bar{g}(\mathbf{x})^2 \\ &= \mathbb{E}_D [g_D(\mathbf{x})^2] - 2 \bar{g}(\mathbf{x})^2 + \bar{g}(\mathbf{x})^2 \\ &= \mathbb{E}_D [g_D(\mathbf{x})^2] - \bar{g}(\mathbf{x})^2\end{aligned}$$

ค่ารวมทั้งช่วง $\text{variance} = \mathbb{E}_{\mathbf{x}} [\text{var}(\mathbf{x})] = 1.69$

ความกว้าง หมายถึง แบบจำลองจากชุดข้อมูลต่างกันเพียง
จากเส้นเฉลี่ยมากเพียงใด





Bias — ความห่างจากเป้าหมาย

ณ แต่ละจุด $\mathbf{x}$


$$\text{bias}(\mathbf{x})^2 = (\bar{g}(\mathbf{x}) - f(\mathbf{x}))^2$$

ค่ารวมทั้งช่วง $\text{bias}^2 = \mathbb{E}_{\mathbf{x}}[\text{bias}(\mathbf{x})^2] = 0.21$

ความห่าง หมายถึง แม้จะลื่นหลายชุดข้อมูลแล้ว แบบจำลอง
จะลื่นยังเบี่ยงจากเป้าหมาย เนื่องจากเส้นตรงแทน $\sin$ ไม่ได้



Bias–Variance Decomposition





$$\mathbb{E}_D[E_{\text{out}}] = \mathbb{E}_{\mathbf{x}}[\text{bias}(\mathbf{x})^2 + \text{var}(\mathbf{x})]$$

$$= \text{bias}^2 + \text{variance} = 0.21 + 1.69 = \mathbf{1.90}$$

ใช้ข้อมูล 2 จุดสร้าง Simple Linear Regression กับปัญหา $\sin$ — โดยเฉลี่ยจะมี $\text{MSE} = \mathbf{1.90}$ (bias ต่ำ แต่ variance สูงมาก)

แบบจำลองไหนดีกว่า?

ลองเทียบกับแบบจำลอง **ค่าคงตัว** $h(x) = b$



Lab 1.1 — E_{in} เทียบ E_{out}

ทดลอง: เปิด [Playground: Generalization ↗](#) แก๊บ E_{in} vs E_{out} — target $\sin \pi x$, $n = 8$. ไล่ model constant → cubic อ่านค่า · ที่ cubic กด **Resample** หลายครั้ง

แบบจำลอง	E_{in}	E_{out}
constant		
linear		
cubic		

สรุปเอง: ยิ่งซับซ้อน E_{in} กับ E_{out} ไปทางใด? กด Resample แล้ว E_{out} นิ่งไหม บอกอะไรเรื่องการสุม?

Lab 1.2 — แบบจำลองเฉลี่ย $\bar{g}$

ทดลอง: เก็บ **Average Fit** กด **Play** สะสมข้อมูล สังเกตเส้น $\bar{g}$ (ทึบ) เทียบเส้นทฤษฎี (ประ) ที่ d น้อย $\rightarrow$ มาก

d (จำนวนชุด)	$\bar{g}$ ห่างจากเส้นทฤษฎี
น้อย	
มาก	

สรุปเอง: ต้องสุ่มมากแค่ไหน $\bar{g}$ ถึงลู่เข้าเส้นทฤษฎี? สุ่มน้อย เชื่อ $\bar{g}$ ได้ไหม?

Lab 1.3 — bias^2

ทดลอง: แก๊บ **Bias** กด **Play** จนนิ่ง อ่าน bias^2 เมื่อปรับทีละอย่าง: complexity, n , σ

ปรับ	bias^2 เปลี่ยน (↑/↓)
complexity ↑	
n ↑	
σ ↑	

สรุปเอง: bias^2 ขึ้นกับอะไรบ้าง? อะไรทำให้ลด อะไรไม่มีผล?

Lab 1.4 — variance

ทดลอง: แก๊บ **Variance** กต **Play** จนนึ่ง อ่าน variance เมื่อปรับทีละอย่าง: complexity, n , σ

ปรับ	variance เปลี่ยน (↑/↓)
complexity ↑	
n ↑	
σ ↑	

สรุปเอง: variance ขึ้นกับอะไรบ้าง? อะไรทำให้ลด? ต่างจาก bias^2 อย่างไร?


Lab 1.5 — E_{out}

ทดลอง: เก็บ **Compare Models** อ่านตาราง E_{out} ทั้ง 4 model · เปลี่ยน n, σ ดูว่าตัวที่ดีที่สุดเปลี่ยนไหม

แบบจำลอง	E_{out}
constant	
linear	
cubic	

สรุปเอง: ตัวไหน E_{out} ต่ำสุด? เปลี่ยน n/σ แล้วตัวที่ดีที่สุดเปลี่ยนไหม? E_{out} ประกอบด้วยอะไร?

ผลลัพธ์ที่น่าประหลาดใจ



Model	bias ²	variance	E_{out}
ค่าคงตัว	0.50	0.25	0.75
เชิงเส้น	0.21	1.69	1.90

เมื่อข้อมูลน้อย แบบจำลอง**ค่าคงตัว**ชนะ — แม้ bias สูงกว่า แต่ variance ต่ำกว่ามาก

แถบ**ชมพู** = ความกว้างของ variance รอบเส้นเฉลี่ย

นิยาม Expectation (ค่าคาดหวัง)

สำหรับตัวแปรสุ่มต่อเนื่อง X ที่มีความหนาแน่นของความน่าจะเป็น $p(x)$

$$\mathbb{E}[X] = \int x p(x) dx$$

คือค่าเฉลี่ยของ X ถ่วงน้ำหนักด้วยความน่าจะเป็น — หากสุ่มค่ามาจำนวนมากแล้วเฉลี่ย จะลู่เข้าค่านี้

Expectation เหนือชุดข้อมูล

ในบทนี้ใช้กับฟังก์ชัน h เหนือทุกชุดข้อมูล D

$$\mathbb{E}_D[h] = \int h(D) p(D) dD$$

ในทำนองเดียวกัน $\mathbb{E}_{\mathbf{x}}[\cdot]$ เหนือทุกจุดอินพุต $\mathbf{x}$


การแจกแจงแบบต่อเนื่องทำให้ผลรวมกลายเป็นอินทิเกรต

นี่คือที่มาที่ทำให้เราคำนวณ bias และ variance ของแบบจำลองค่าคงตัวได้แบบ analytic ในหน้าถัดไป


Constant Model — พิสูจน์เชิง Analytic

$$g_D(\mathbf{x}) = \frac{\sin(\pi x_1) + \sin(\pi x_2)}{2}$$

แบบจำลองทำนายค่าคงที่ = ค่าเฉลี่ยของ y สองจุด · กรณีนี้
อินทิเกรตหาค่าได้โดยตรง ต่างจากเชิงเส้นที่ต้องประมาณ



แบบจำลองเฉลี่ย (ค่าคงตัว)



ข้อมูลสุ่มจาก $x_1, x_2 \sim \text{Uniform}[-1, 1]$ ความหนาแน่น $p(x) = \frac{1}{2}$ ต่อแกน


$$\bar{g}(\mathbf{x}) = \mathbb{E}_D[g_D(\mathbf{x})] = \int_{-1}^1 \int_{-1}^1 \frac{\sin(\pi x_1) + \sin(\pi x_2)}{2} p(x_1)p(x_2) dx_1 dx_2$$

$$= \frac{1}{4} \int_{-1}^1 \int_{-1}^1 \frac{\sin(\pi x_1) + \sin(\pi x_2)}{2} dx_1 dx_2 = 0$$

พิสูจน์ค่าคงตัว (1) — Bias

$$\begin{aligned}\text{bias}(\mathbf{x})^2 &= (\bar{g}(\mathbf{x}) - f(\mathbf{x}))^2 \\ &= (0 - \sin \pi x)^2 = \sin^2(\pi x) \\ \text{bias}^2 &= \mathbb{E}_{\mathbf{x}}[\text{bias}(\mathbf{x})^2] = \frac{1}{2} \int_{-1}^1 \sin^2(\pi x) dx = 0.5\end{aligned}$$

แทน $\bar{g} = 0$ และ $f = \sin \pi x$ ก่อน แล้วจึงอินทิเกรต





พิสูจน์ค่าคงตัว (2) — Variance

$$\text{var}(\mathbf{x}) = \mathbb{E}_D [g_D(\mathbf{x})^2] - \bar{g}(\mathbf{x})^2, \quad \bar{g} = 0$$

$$= \frac{1}{4} \int_{-1}^1 \int_{-1}^1 \left(\frac{\sin \pi x_1 + \sin \pi x_2}{2} \right)^2 dx_1 dx_2 = 0.25$$

$$\text{variance} = \mathbb{E}_{\mathbf{x}} [\text{var}(\mathbf{x})] = 0.25$$

เขียนในรูปตัวแปรก่อน แล้วแทน $\bar{g} = 0$ และอินทิเกรต



Bias–Variance Tradeoff

bias สูง หมายถึง แบบจำลองเรียบง่ายเกินไป จนจับรูปแบบของข้อมูลไม่ได้


variance สูง หมายถึง แบบจำลองยืดหยุ่นเกินไป จนไวต่อชุดข้อมูลที่สุ่มได้

ความซับซ้อนต้องเหมาะสมกับปริมาณและคุณภาพข้อมูล ไม่ใช่เหมาะสมกับความซับซ้อนของเป้าหมาย

การทดลอง — ฟิตที่ n ต่าง ๆ

ทดลองฟิตแบบจำลองเชิงเส้นด้วยจำนวนตัวอย่าง $n = 2, 5, 10$ จากหลายชุดข้อมูล (แถวล่างแสดงเส้นสุ่มและเส้นเฉลี่ย)

วัดค่า E_{in} และ E_{out} เฉลี่ยที่แต่ละ n เพื่อนำไปสร้างเส้นการเรียนรู้




Learning Curve

นำค่า E_{in} และ E_{out} ที่วัดจากการทดลอง มาแสดงเทียบกับ
จำนวนตัวอย่าง n

$\mathbb{E}_D[E_{\text{in}}], \mathbb{E}_D[E_{\text{out}}]$ เทียบกับ n


แสดงว่าเมื่อข้อมูลเพิ่มขึ้น ค่าคลาดเคลื่อนทั้งสองเปลี่ยนแปลง
และลู่เข้าหากันอย่างไร



ข้อสังเกต 1

$$n \uparrow \Rightarrow E_{\text{in}} \uparrow$$


ที่ $n = 2$ เส้นตรงผ่านทุกจุด ได้ $E_{\text{in}} = 0$ เสมอ เมื่อ $n > 2$
ค่า E_{in} มากกว่าศูนย์



ข้อสังเกต 2

$$n \uparrow \Rightarrow \text{var} \downarrow \Rightarrow E_{\text{out}} \downarrow$$


ข้อมูลมากขึ้น เส้นเสถียรขึ้น ความแปรปรวนลดลง — E_{out}
(แดง) ลดเข้าหาเส้น bias




ข้อสังเกต 3

$$\lim_{n \rightarrow \infty} \text{var} = 0 \Rightarrow E_{\text{out}} = E_{\text{in}} = \text{bias}$$

E_{in} กับ E_{out} ลู่เข้าหากันที่ค่าความเอนเอียง (เส้นดำ)




Simple เทียบ Complex



- แบบจำลองอย่างง่าย **ลู่เข้าเร็วกว่า** แต่หยุดที่ Error สูงกว่า
- แบบจำลองซับซ้อนลู่เข้าช้ากว่า แต่ข้อมูลมากพอจะได้ Error ต่ำกว่า

Learning Curve = Bias² + Variance




$$\mathbb{E}_D[E_{out}] = \text{bias}^2 + \text{variance}$$

เส้นแดง = E_{out} ทฤษฎี · น้ำเงิน = E_{in}

พื้นที่แดง = variance · น้ำเงิน = bias^2 · ข้อมูลมากขึ้น
variance ลด สองเส้นลู่เข้าหากัน

เป้าหมายไม่มีสัญญาณรบกวน




$$\mathbb{E}_D[E_{out}] = \text{bias}^2 + \text{variance}$$

ลด E_{out} ได้ 2 ทาง: เพิ่มความซับซ้อน (ลด bias) หรือเพิ่มข้อมูล (ลด variance) — H_3 ลู่หา 0 ได้


เป้าหมายมีสัญญาณรบกวน

ข้อมูลจริงมี noise: $f(x) = \sin(\pi x) + \epsilon$, $\epsilon \sim \mathcal{N}(0, \sigma^2)$



σ = การกระจายของจุดรอบเส้น (ความกว้างของระฆังในรูป) $\cdot \sigma^2$ = ความแปรปรวนของ noise = ค่าคลาดเคลื่อนที่ลดไม่ได้


Noisy Target — Learning Curve



$$\mathbb{E}_D[E_{\text{out}}] = \sigma^2 + \text{bias}^2 + \text{variance}$$

$n \uparrow \Rightarrow \text{var} \downarrow$ แต่ σ^2 ลดไม่ได้ — เส้น E_{out} ลู่เข้าที่ **พื้** = $\sigma^2 + \text{bias}^2$ (ในรูป H_3 ที่ $\text{bias} \approx 0$ พื้จึง $\approx \sigma^2$)

Bias-Variance กับ Noise



ไม่มี noise (ซ้าย): H_3 ชนะเมื่อข้อมูลพอ · มี noise (ขวา): H_3 อาจแย่กว่า H_1 เพราะไปฟิต noise

ค่าคลาดเคลื่อนที่ลดไม่ได้

σ^2 คือ **irreducible error**

เพิ่มข้อมูลหรือความซับซ้อนเท่าใด ก็ลดพจน์นี้ไม่ได้


เป้าหมายสองข้อของการเรียนรู้

- ทำให้ E_{in} **เล็ก** — ต้องจับช้อนพอ (ลด bias)
- ทำให้ E_{out} **ใกล้** E_{in} — ต้องไม่จับช้อนเกิน (คุม variance)

สองข้อนี้ **ตึงกันคนละทาง** — เลือกความจับช้อนพอดี คือหัวใจของบทถัด ๆ ไป

เชื่อมกับการฟิตเกิน

variance สูง = **ฟิตเกิน** — E_{in} ต่ำแต่ E_{out} สูง



สรุป: สามองค์ประกอบของ E_{out}

$$\mathbb{E}_D[E_{out}] = \sigma^2 + \text{bias}^2 + \text{variance}$$

องค์ประกอบ	ความหมาย	ลดได้ด้วย
bias²	แบบจำลองเฉลี่ยห่างจากเป้าหมาย (เรียบง่ายเกินไป)	เพิ่มความซับซ้อน (M สูงขึ้น)
variance	แบบจำลองแกว่งตามชุดข้อมูล (ยืดหยุ่นเกินไป)	เพิ่มข้อมูล (n) หรือลดความซับซ้อน
σ^2 (noise)	ความรบกวนในข้อมูลเอง	ลดไม่ได้ (irreducible)

บทถัดไป

- **Performance Estimation** — วิธีประมาณ E_{out} จากข้อมูลจริง (validation / test) เพราะคำนวณโดยตรงไม่ได้
- **Model Selection** — เลือกความซับซ้อนที่สมดุล bias-variance
- **Regularization** — ควบคุม variance โดยจำกัดความยืดหยุ่นของแบบจำลอง

bias-variance ที่เรียนในบทนี้ คือหลักคิดกลางของทั้งสามเรื่องข้างต้น

Lab 2.1 — Learning Curve (ทฤษฎี)

ทดลอง: เปิด [Playground: Learning Curve](#) ↗ แก้ไข **Theory**, model linear — อ่าน $E_{\text{in}}, E_{\text{out}}$ ที่ $n = 4, 20, 60$

n	E_{in}	E_{out}
4		
20		
60		

สรุปเอง: เมื่อ n เพิ่มขึ้น E_{in} ไปทางใด, E_{out} ไปทางใด, และทั้งคู่เข้าสู่ที่ระดับใด?

Lab 2.2 — ทฤษฎี vs ปฏิบัติ

ทดลอง: เก็บ **Practice** (ข้อมูลจำกัด) ดูเส้นวัด (ทึบ) เทียบเส้นทฤษฎี (ประ) ก่อนกด Play แล้วกด **Play** สะสมเรื่อย ๆ

จำนวนรอบ	เส้นวัดห่างจากทฤษฎี
น้อย	
มาก	

สรุปเอง: ข้อมูล/รอบน้อย เส้นวัดต่างจากทฤษฎีอย่างไร? กด Play มากขึ้นเป็นอย่างไร? คำว่า “expected” หมายถึงอะไร?

Lab 2.3 — เลือกแบบจำลอง (overfit / underfit)

ทดลอง: เก็บ **Simple vs Complex** — model A = linear, B = cubic หาจุดตัด (crossing) · เปลี่ยน σ ดูโซน overfit/underfit

σ	จุดตัด n
น้อย	
มาก	

สรุปเอง: ก่อน/หลังจุดตัด ควรเลือกโมเดลใด? เพิ่ม noise จุดตัดขยับทางใด? โซน overfit/underfit อยู่ฝั่ง n น้อยหรือมาก?

สรุป

- เป้าหมายจริง คือ E_{out} ต่ำ ไม่ใช่แค่ E_{in}
- $E_{\text{out}} = \sigma^2 + \text{bias}^2 + \text{variance}$
- bias สูง = เรียบเกินไป · variance สูง = ยืดหยุ่นเกินไป
- ข้อมูลมากขึ้นลด variance และ $E_{\text{in}}, E_{\text{out}}$ ลู่เข้าหากัน